

図表5-3 安全性の指針の内容

・AIシステム・サービスの出力の正確性を含め、要求に対して十分に動作している（信頼性）。 ・さまざまな状況下でパフォーマンスレベルを維持し、無関係な事象に対して著しく誤った判断を発生させないようにする（堅牢性（robustness））。 ・AIの活用または意図しないAIの動作によって生じる権利侵害の重大性、侵害発生の可能性等、当該AIの性質・用途等に照らし、必要に応じて定期的かつ客観的なモニタリングおよび対処も含めて人間がコントロールできる制御可能性を確保する。 ・適切なリスク分析を実施し、リスクへの対策（回避、低減、移転または容認）を講じる。 ・人間の生命・身体・財産、精神および環境へ危害を及ぼす可能性がある場合は、講ずべき措置について事前に整理し、ステークホルダーに関連する情報を提供する。 ※関連するステークホルダーが講ずべき措置および利用規則を明記する。 ・AIシステム・サービスの安全性を損なう事態が生じた場合の対処方法を検討し、当該事態が生じた場合に速やかに実施できよう整える。	人間の生命・身体・財産、精神および環境への配慮 適正利用 適正学習
--	--

偽情報等への対策	生成AIによって、内容が真実・公平であるかのように装った情報を誰でも作ることができるようになり、AIが生成した偽情報・誤情報・偏向情報が社会を不安定化・混乱させるリスクが高まっていることを認識した上で、必要な対策を講じる（※3）。 公平性の確保に加え、いわゆる「情報弱者」および「技術弱者」を生じさせず、より多くの人々がAIの恩恵を享受できるように社会的弱者によるAIの活用を容易にするよう注意を払う。 例）ユニバーサルデザイン、アクセシビリティの確保、関連するステークホルダー（※4）への教育・フォローアップ等
利用者支援	合理的な範囲で、AIシステム・サービスの機能およびその周辺技術に関する情報を提供し、選択の機会の判断のための情報を適時かつ適切に提供する機能が利用可能である状態とする。 例）デフォルトの設定、理解しやすい選択肢の提示、フィードバックの提供、緊急時の警告、エラーへの対処等 ・AIシステム・サービスの開発・提供・利用において、ライフサイクル全体で、地球環境への影響も検討する。 ・生成AIなど計算量の多いAIシステムでは、モデルの軽量化や目的に応じたモデルの使い分け等の必要な対策を講じる。

※3：インターネット上の偽情報・誤情報への対応を含む「デジタル空間における情報流通の健全性確保の在り方に関する検討会」（総務省）により、制度面も含め、表現の自由をはじめとするさまざまな権利利益に配慮した総合的な検討が行われました。

https://www.soumu.go.jp/main_sosiki/kenkyu/digital_space/index.html

※4：AI開発者、AI提供者、AI利用者、業務外利用者を含む、直接・間接的にAIの活用に関与する主体を指します。

「安全性」の指針に含まれるものは、次のとおりです。